

LAPORAN AKHIR

SEGMENTASI DAN PREDIKSI HARGA PENGINAPAN DI SURABAYA PADA APLIKASI TRAVELOKA MENGGUNAKAN *K-MEANS CLUSTERING* DAN *RANDOM FOREST*



KELOMPOK : SD-A1 - 03

- | | |
|-----------------------------|-----------|
| 1. Naura Salsabila Faradian | 164231020 |
| 2. Mirza Muhyidin | 164231060 |
| 3. Ryan Zufar Ahmadi | 164231096 |
| 4. Haneda Linda Pratiwi | 164231103 |
| 5. Arya Putra Permana | 164231106 |

**TEAM-BASED PROJECT
MATA KULIAH DATA MINING I
PROGRAM STUDI TEKNOLOGI SAINS DATA
FAKULTAS TEKNOLOGI MAJU DAN MULTIDISIPLIN
UNIVERSITAS AIRLANGGA
2025**

DAFTAR ISI

DAFTAR ISI.....	i
DAFTAR TABEL.....	iii
DAFTAR GAMBAR.....	iv
BAB I	
PENDAHULUAN.....	1
1.1 LATAR BELAKANG.....	1
1.2 RUMUSAN MASALAH.....	2
1.3 TUJUAN.....	3
1.4 MANFAAT.....	3
BAB II	
TINJAUAN PUSTAKA.....	4
2.1 <i>CLUSTERING</i>	4
2.1.1 Pengertian <i>Clustering</i>	4
2.1.2 <i>K-Means</i>	4
2.2 ANALISIS REGRESI.....	5
2.2.1 Pengertian Regresi.....	5
2.2.2 <i>Random Forest</i>	5
2.3 TRAVELOKA DAN DATA PENGINAPAN.....	6
BAB III	
METODOLOGI.....	7
3.1 SUMBER DATA.....	7
3.2 VARIABEL PENELITIAN.....	7
3.3 LANGKAH ANALISIS PENELITIAN.....	8
3.3.1 <i>Exploratory Data Analysis (EDA)</i> dan <i>Data Preprocessing</i>	8
3.3.2 Algoritma <i>Machine Learning K-Means Clustering</i>	9
3.3.3 Algoritma <i>Machine Learning Random Forest Regression</i>	10
BAB IV	
HASIL DAN PEMBAHASAN.....	11
4.1 <i>EXPLORATORY DATA ANALYSIS (EDA)</i> DAN <i>DATA-PREPROCESSING</i>	11
4.1.1 Statistika Deskriptif.....	11
4.1.2 Pengecekan dan Penanganan <i>Missing Values</i>	11
4.1.3 Pengecekan <i>Outlier</i>	12
4.1.4 Transformasi Variabel.....	14
4.1.5 Korelasi Antar Variabel.....	15

4.2 HASIL ANALISIS.....	15
4.2.1 <i>K-Means Clustering</i>	15
4.2.2 <i>Random Forest Regression</i>	18
BAB V	
KESIMPULAN DAN SARAN.....	20
5.1 KESIMPULAN.....	20
5.2 SARAN.....	20
DAFTAR PUSTAKA.....	22
LAMPIRAN.....	23

DAFTAR TABEL

Tabel 1. Variabel Penelitian.....	7
Tabel 2. Hasil Statistika Deskriptif.....	11
Tabel 3. Hasil Pengecekan <i>Missing Values</i>	11
Tabel 4. Hasil Pengecekan <i>Outlier</i>	12
Tabel 5. Data dan Variabel Setelah Transformasi.....	14
Tabel 6. Kuartil Tiap <i>Cluster</i>	17

DAFTAR GAMBAR

Gambar 1. <i>Scrapping</i> situs web Traveloka pencarian penginapan di Surabaya.....	7
Gambar 2. <i>Boxplot</i> persebaran <i>outlier</i>	13
Gambar 3. <i>Heatmap</i> Korelasi Variabel Numerik.....	15
Gambar 4. Kode untuk memisahkan variabel ‘Harga dalam semalam’.....	16
Gambar 5. Kode untuk Standarisasi.....	16
Gambar 6. Distribusi harga untuk setiap cluster.....	17
Gambar 7. Kode untuk membagi data menjadi data X dan Y serta membagi data menjadi <i>data train</i> dan <i>data test</i>	18
Gambar 8. Kode untuk menambahkan <i>feature</i> baru.....	19

BAB I

PENDAHULUAN

1.1 LATAR BELAKANG

Surabaya merupakan kota metropolitan terbesar kedua di Indonesia yang memiliki peran penting sebagai pusat bisnis, pendidikan, dan pariwisata di wilayah Jawa Timur. Keberadaan berbagai destinasi wisata populer seperti Monumen Kapal Selam, Kebun Binatang Surabaya, serta pusat perbelanjaan besar seperti Tunjungan Plaza dan Pakuwon Mall menjadikan kota ini sebagai salah satu tujuan favorit wisatawan domestik maupun mancanegara. Tingginya angka kunjungan wisatawan berdampak langsung pada meningkatnya kebutuhan akan akomodasi, khususnya penginapan, di Surabaya.

Seiring dengan meningkatnya mobilitas masyarakat dan perkembangan teknologi digital, masyarakat kini cenderung menggunakan platform daring seperti Traveloka untuk mencari dan memesan penginapan. Namun, banyaknya pilihan penginapan dengan harga yang sangat bervariasi sering kali menimbulkan kebingungan dalam memilih opsi yang paling sesuai dengan preferensi pengguna. Di sisi lain, pelaku industri penginapan juga dihadapkan pada tantangan dalam menetapkan harga yang kompetitif di tengah dinamika pasar yang cepat berubah. Pada saat melakukan reservasi penginapan sebaiknya diteliti terlebih dahulu fasilitas-fasilitas yang disediakan oleh pihak penginapan, lokasi penginapan, dan juga yang harus dipertimbangkan adalah harga sewanya supaya dapat mengambil keputusan apakah menginap atau dibatalkan reservasi penginapannya. Pengalaman yang kurang dalam hal reservasi penginapan dapat menyebabkan dibatalkannya reservasi penginapannya.

Harga sebuah kamar penginapan dipengaruhi oleh berbagai faktor seperti jumlah *rating*, bintang, fasilitas, lokasi, jumlah ulasan, dan penilaian pengguna. Oleh karena itu, analisis yang mendalam terhadap struktur dan pola harga penginapan sangat dibutuhkan untuk membantu konsumen dalam pengambilan keputusan dengan harga yang tepat.

Guna menjawab kebutuhan tersebut, penelitian ini bertujuan untuk menganalisa dan memprediksi harga penginapan di Surabaya menggunakan pendekatan berbasis data. Terdapat dua metode utama yang digunakan dalam penelitian ini. Pertama, metode *K-Means Clustering* diterapkan untuk melakukan segmentasi harga penginapan guna mengelompokkan penginapan ke dalam kategori seperti harga terendah, harga menengah, dan harga tertinggi. Segmentasi ini bertujuan untuk memahami distribusi dan kecenderungan harga di pasar. Menurut Koko Handoko (2016), algoritma *K-Means Clustering* berupa proses pengelompokan sejumlah data atau objek ke dalam *cluster (group)* sehingga setiap dalam *cluster* tersebut akan berisi data yang semirip mungkin dan berbeda dengan objek dalam *cluster* yang lainnya.

Kedua, algoritma yang digunakan adalah *Random Forest* yang berfungsi untuk membangun model prediktif yang mampu mengidentifikasi faktor-faktor utama yang memengaruhi harga penginapan. Dengan mempertimbangkan variabel seperti *rating* penginapan, bintang, fasilitas, lokasi, dan ulasan pengguna, metode *Random Forest* dipilih karena kemampuannya dalam menangani data yang kompleks dan non-linear, serta memberikan output berupa nilai pentingnya masing-masing fitur. Menurut Pramoedyo (2022), *Random forest* adalah pengembangan dari *decision tree* (pohon keputusan) dengan menggunakan banyak *decision tree*, di mana setiap *decision tree* telah dilatih menggunakan sampel individual dan setiap atribut dibagi ke dalam pohon yang dipilih dari serangkaian atribut acak, dan setiap atribut dibagi ke dalam pohon yang dipilih dari himpunan bagian atribut acak, dan setiap atribut dibagi ke dalam pohon yang dipilih dari serangkaian atribut acak, dan setiap atribut. *Random forest* merupakan teknik organisasi yang mengumpulkan variabel independen serta data sampel, menghasilkan pohon klasifikasi dengan berbagai ukuran dan bentuk.

Pemilihan metode ini mengacu pada hasil penelitian sebelumnya yang menggunakan metode *Random Forest* dan *Deep Learning*. Penelitian tersebut diambil dari dataset *Kaggle* dengan judul *reservation* penginapan dataset. Nilai *performance* tertinggi pada model dengan menggunakan metode *Random Forest* adalah akurasi 76,86%, presisi 83,45% dan *recall* 84,03%. Dengan mengadaptasi pendekatan serupa namun menggunakan algoritma yang lebih kuat seperti *Random Forest* dan segmentasi berbasis *clustering*, penelitian ini diharapkan memberikan kontribusi yang lebih relevan terhadap analisis harga penginapan secara langsung.

Melalui pendekatan gabungan antara segmentasi harga dan pemodelan prediksi, penelitian ini diharapkan dapat memberikan wawasan strategis yang bermanfaat bagi pelaku industri yang mempunyai usaha penginapan serta membantu konsumen dalam membuat keputusan yang lebih tepat.

1.2 RUMUSAN MASALAH

Berdasarkan uraian latar belakang diatas, maka permasalahan dalam penelitian dapat diuraikan sebagai berikut:

1. Bagaimana cara mengelompokkan penginapan di Surabaya berdasarkan harga menggunakan metode *Clustering*?
2. Bagaimana cara memprediksi harga penginapan berdasarkan fitur-fitur seperti *rating* penginapan, fasilitas, jarak, jumlah ulasan, dan *rating* menggunakan algoritma *Random Forest*?
3. Faktor apa saja yang paling berpengaruh terhadap pembentukan harga penginapan di Surabaya berdasarkan hasil model *Random Forest*?
4. Bagaimana hasil segmentasi dan prediksi harga penginapan dapat membantu pengguna aplikasi dan pelaku industri yang mempunyai usaha penginapan dalam pengambilan keputusan?

1.3 TUJUAN

Berdasarkan rumusan masalah di atas, maka tujuan penelitian ini adalah sebagai berikut:

1. Mengetahui cara mengelompokkan penginapan di Surabaya berdasarkan rentang harga menggunakan metode *K-Means Clustering*.
2. Mengetahui cara memprediksi harga penginapan berdasarkan fitur-fitur seperti *rating* penginapan, fasilitas, jarak dari pusat kota, jumlah ulasan, dan jumlah ulasan pengguna menggunakan algoritma *Random Forest*.
3. Mengetahui faktor-faktor yang paling berpengaruh terhadap harga penginapan berdasarkan hasil analisis model *Random Forest*.
4. Mengetahui bagaimana hasil segmentasi dan prediksi harga penginapan dapat digunakan untuk membantu pengguna aplikasi dan pelaku industri yang mempunyai usaha penginapan dalam pengambilan keputusan yang lebih tepat.

1.4 MANFAAT

Peneliti berharap penelitian ini dapat bermanfaat untuk:

1. Meningkatkan wawasan dan pengetahuan mengenai segmentasi dan prediksi harga penginapan menggunakan metode *data mining*.
2. Membantu pengguna Traveloka dalam memilih penginapan yang sesuai dengan kebutuhan dan anggaran mereka.
3. Menjadi acuan untuk penelitian selanjutnya yang berkaitan dengan analisis harga penginapan dan perilaku konsumen di sektor pariwisata.

BAB II

TINJAUAN PUSTAKA

2.1 **CLUSTERING**

2.1.1 **Pengertian *Clustering***

Clustering merupakan salah satu teknik dalam *unsupervised learning* yang digunakan untuk mengelompokkan sekumpulan data ke dalam beberapa grup (*cluster*), sehingga data dalam satu *cluster* memiliki kemiripan yang tinggi satu sama lain dan berbeda secara signifikan dengan data yang berada di *cluster* lainnya (Han, Kamber, & Pei, 2012). Proses *clustering* tidak menggunakan label atau kategori yang sudah ditentukan sebelumnya, sehingga algoritma secara otomatis akan mencari struktur atau pola tersembunyi dalam data.

Tujuan utama dari *clustering* adalah untuk menemukan struktur alami dalam data, menyederhanakan kompleksitas data, dan mengidentifikasi kelompok-kelompok tersembunyi berdasarkan kesamaan tertentu. Dalam konteks *data mining*, *clustering* sering digunakan untuk segmentasi pelanggan, deteksi anomali, pengelompokan dokumen, hingga pengelompokan harga seperti dalam penelitian ini (Tan, Steinbach, & Kumar, 2019). *Clustering* juga dapat meningkatkan efisiensi dan efektivitas proses analisis data dengan menyajikan data dalam bentuk kelompok-kelompok yang lebih mudah dipahami dan diinterpretasikan.

2.1.2 ***K-Means***

Dalam penelitian ini, metode *K-Means* digunakan untuk melakukan segmentasi harga penginapan berdasarkan kemiripan nilai harga. *K-Means* merupakan algoritma *unsupervised learning* yang bekerja dengan membagi data ke dalam k *cluster* berdasarkan jarak ke pusat *cluster* (*centroid*) menggunakan jarak Euclidean sebagai ukuran kemiripan (Han, Kamber, & Pei, 2012). Meskipun hanya menggunakan satu fitur, yaitu harga, *K-Means* tetap efektif dalam mengelompokkan data ke dalam segmen-segmen yang bermakna. Tujuan utama penggunaan *K-Means* dalam konteks ini adalah untuk mengidentifikasi kelompok harga penginapan di Surabaya, seperti kelompok penginapan dengan harga rendah, menengah, dan tinggi. Hasil dari proses *clustering* ini berupa pengelompokan penginapan ke dalam beberapa *cluster*, di mana masing-masing *cluster* akan merepresentasikan rentang harga tertentu. Dengan demikian, metode ini membantu dalam memahami struktur distribusi harga di pasar, serta memberikan dasar yang kuat untuk analisis lanjutan, seperti prediksi harga menggunakan model *supervised learning* seperti *Random Forest*.

2.2 ANALISIS REGRESI

2.2.1 Pengertian *Regresi*

Regresi adalah metode analisis statistik yang digunakan untuk memahami hubungan antara variabel dependen (respon) dan satu atau lebih variabel independen (prediktor). Dalam konteks prediksi harga penginapan, regresi digunakan untuk memperkirakan nilai harga berdasarkan faktor-faktor tertentu, seperti jenis penginapan, lokasi, dan fasilitas. Teknik regresi yang umum digunakan dalam analisis prediktif adalah regresi linier dan regresi pohon keputusan (*decision tree regression*), yang dapat digunakan untuk meramalkan harga berdasarkan input data.

Regresi memungkinkan kita untuk mengidentifikasi pola atau hubungan antara harga penginapan dan berbagai faktor yang mempengaruhinya, yang penting dalam proses segmentasi pasar dan pengelompokan penginapan berdasarkan harga. Dalam penelitian ini, regresi digunakan untuk membangun model prediksi harga penginapan yang akurat setelah melakukan segmentasi dengan teknik *K-Means Clustering*.

Menurut Hastie et al. (2009), regresi memberikan wawasan yang mendalam tentang bagaimana variabel-variabel prediktor mempengaruhi hasil yang diprediksi, yang dalam hal ini adalah harga penginapan. Hal ini sangat berguna dalam analisis harga dinamis, terutama dalam aplikasi seperti Traveloka, dimana harga dapat bervariasi tergantung pada sejumlah faktor.

2.2.2 *Random Forest*

Random Forest merupakan salah satu algoritma pembelajaran mesin berbasis *ensemble learning* yang dikembangkan oleh Leo Breiman bersama Adele Cutler pada awal tahun 2000. Algoritma ini merupakan pengembangan dari metode *bagging* (*Bootstrap Aggregating*) yang sebelumnya diperkenalkan Breiman pada tahun 1996. Motivasi di balik pengembangan *Random Forest* adalah untuk mengatasi kelemahan pohon keputusan tunggal yang cenderung mengalami *overfitting* ketika digunakan pada data pelatihan yang kompleks. Breiman memperkenalkan pendekatan baru dengan membangun banyak pohon keputusan dari subset data yang berbeda menggunakan teknik *bootstrap*, serta menambahkan proses pemilihan fitur secara acak di setiap *node* untuk memperkuat variasi dan mengurangi korelasi antar pohon.

Secara teknis, *Random Forest* bekerja dengan menghasilkan sejumlah pohon keputusan berdasarkan data latih yang dibagi ke dalam subset secara acak. Setiap pohon hanya memanfaatkan sebagian fitur dari keseluruhan fitur yang tersedia saat menentukan pemisahan terbaik di tiap *node*. Penggabungan hasil dari semua pohon dilakukan melalui mekanisme *voting* (untuk klasifikasi) atau rata-rata (untuk regresi). Kombinasi teknik *bootstrap sampling* dan pemilihan fitur acak ini menjadikan *Random Forest* unggul dalam hal akurasi, stabilitas, dan ketahanan terhadap *overfitting*.

Berbagai studi empiris telah menunjukkan bahwa *Random Forest* mampu mengelola data berukuran besar, berdimensi tinggi, serta data yang mengandung ketidaksempurnaan seperti nilai hilang atau korelasi antar fitur. Selain sebagai model prediktif, *Random Forest* juga banyak digunakan sebagai alat analisis eksploratif karena kemampuannya dalam mengukur pentingnya setiap fitur melalui indikator seperti *Gini Importance* atau *Mean Decrease in Impurity*. Dengan kombinasi antara akurasi tinggi, kemudahan penggunaan, dan interpretabilitas yang baik, *Random Forest* tetap menjadi salah satu algoritma yang paling banyak diadopsi dalam pengembangan sistem cerdas dan penelitian ilmiah berbasis data hingga saat ini.

2.3 TRAVELOKA DAN DATA PENGINAPAN

Traveloka adalah salah satu platform digital terkemuka di Asia Tenggara yang menyediakan layanan pemesanan berbagai kebutuhan perjalanan dan gaya hidup, termasuk tiket pesawat, akomodasi, transportasi, hingga aktivitas wisata. Didirikan pada tahun 2012, Traveloka berkembang menjadi platform yang menyajikan jutaan pilihan penginapan dan penginapan di berbagai kota, termasuk Surabaya, dengan fitur yang memudahkan pengguna dalam membandingkan dan memilih akomodasi sesuai kebutuhan dan anggaran mereka.

Dalam konteks analisis data, Traveloka menyediakan berbagai atribut informasi terkait penginapan yang dapat dijadikan sebagai variabel dalam proses segmentasi dan prediksi. Beberapa jenis data penginapan yang umumnya tersedia antara lain.

- Harga kamar: Menampilkan harga sewa kamar per malam
- Lokasi: Alamat atau koordinat geografis penginapan.
- *Rating* dan ulasan pengguna: Menunjukkan kualitas pelayanan dan kepuasan tamu yang pernah menginap.
- Fasilitas penginapan: Misalnya WiFi gratis, kolam renang, sarapan, parkir, AC, restoran, dan sebagainya.
- Jumlah bintang: Menggambarkan tingkat atau kelas dari penginapan (misalnya penginapan bintang 3, bintang 4, dll).


Data-data tersebut sangat relevan dalam proses segmentasi karena dapat digunakan untuk mengelompokkan penginapan-penginapan ke dalam beberapa kategori berdasarkan kesamaan fitur, seperti harga atau fasilitas. Misalnya, penginapan-penginapan murah dengan fasilitas minim bisa dikelompokkan dalam satu *cluster*, sementara penginapan mewah dengan layanan lengkap berada di *cluster* lain. Hasil segmentasi ini bermanfaat untuk pemahaman pasar dan strategi pemasaran.

Selain itu, data tersebut juga mendukung proses prediksi harga. Dengan menganalisis hubungan antara variabel-variabel seperti lokasi, *rating*, dan fasilitas terhadap harga, model prediksi seperti *Random Forest* dapat dibangun untuk memperkirakan harga penginapan yang optimal. Hal ini dapat digunakan oleh pengguna untuk membandingkan nilai sebuah penginapan, maupun oleh pelaku industri untuk menetapkan harga kompetitif.

BAB III METODOLOGI

3.1 SUMBER DATA

Sumber data yang digunakan dalam *project* ini merupakan data primer yang diperoleh dari hasil *scraping* terhadap penyewaan penginapan pada situs web Traveloka. Kami mengumpulkan beberapa informasi yang akan dijadikan variabel, seperti nama, harga, ulasan, bintang, *rating*, fasilitas, dan jarak penginapan dengan dengan titik Balai Kota Surabaya. Kami berhasil mendapatkan total data sebanyak 315 data untuk melalui beberapa tahap *preprocessing* seperti *cleaning* data serta transformasi hingga data siap untuk digunakan. Data dapat diakses pada link berikut: link



Gambar 1. *Scrapping* situs web Traveloka pencarian penginapan di Surabaya.

3.2 VARIABEL PENELITIAN

Tabel 1. Variabel Penelitian

Nama Variabel	Deskripsi	Tipe	Skala
Nama Penginapan	Nama atau identitas penginapan	Kategorik	Nominal
Harga dalam semalam	Harga sewa kamar per malam	Numerik	Rasio
Bintang Penginapan	Klasifikasi penginapan berdasarkan jumlah bintang (1–5) sebagai indikator kualitas dan fasilitas	Numerik	Ordinal
<i>Rating</i>	Nilai <i>rating</i> penginapan dari pengguna	Numerik	Ordinal

Nama Variabel	Deskripsi	Tipe	Skala
Lokasi Penginapan	Jarak kecamatan penginapan ke Balai Kota Surabaya	Numerik	Rasio
Jumlah <i>Review</i>	Jumlah ulasan yang diberikan pengguna	Numerik	Rasio
Jumlah Fasilitas	Jumlah fasilitas yang tersedia di penginapan	Numerik	Rasio

3.3 LANGKAH ANALISIS PENELITIAN

3.3.1 *Exploratory Data Analysis (EDA) dan Data Preprocessing*

Sebelum analisis dilakukan, perlu dipahami terlebih dahulu karakteristik data melalui *Exploratory Data Analysis* (EDA). Tahapan ini bertujuan untuk mengeksplorasi struktur data, pola, hubungan antar variabel, serta mendeteksi masalah seperti *outlier* dan *missing values*. Selanjutnya dilakukan *data preprocessing*, yaitu proses pembersihan dan persiapan data yang mencakup penanganan nilai hilang, *outlier*, transformasi, dan pemilihan variabel. Kedua tahapan ini memastikan data siap dianalisis secara valid dan representatif. Berikut adalah tahapan-tahapan yang diambil:

a. Statistika Deskriptif

Tahap ini bertujuan untuk merangkum dan menggambarkan karakteristik dasar dari masing-masing variabel dalam dataset. Statistik deskriptif memberikan ringkasan numerik yang menjelaskan pola-pola umum dalam data, seperti nilai tengah (*mean* dan *median*), ukuran sebaran (*range*, *varians*, *standar deviasi*), serta nilai maksimum dan minimum.

b. Pengecekan dan Penanganan *Missing Values*

Keberadaan *missing values* dalam dataset dapat berdampak signifikan terhadap hasil analisis, baik dari segi akurasi maupun interpretasi model. Oleh karena itu, penting untuk mendeteksi keberadaan nilai-nilai yang tidak lengkap sejak awal agar dapat ditangani secara tepat sebelum memasuki tahap analisis lanjutan.

c. Pengecekan *Outlier*

Proses untuk mengidentifikasi nilai-nilai ekstrim atau pencilan yang secara signifikan berbeda dari mayoritas data lainnya. Meskipun demikian, keberadaan *outlier* dapat memberikan dampak besar

terhadap hasil belajar analisis statistik dan pemodelan, sehingga perlu diidentifikasi dan dievaluasi secara cermat.

d. Korelasi Antar Variabel

Tahapan ini melibatkan pemeriksaan hubungan antara variabel-variabel dalam dataset menggunakan matriks korelasi. Korelasi antar variabel membantu mengidentifikasi pola hubungan linier, baik positif maupun negatif, yang dapat memberikan wawasan awal mengenai variabel-variabel yang berpotensi signifikan dalam model.

e. Pemilihan Variabel

Langkah ini bertujuan untuk mengidentifikasi dan memilih subset variabel (fitur) yang paling relevan dan berkontribusi signifikan terhadap model prediktif atau analisis yang akan dibangun. *Feature selection* merupakan bagian penting dari *pipeline data science* karena dapat meningkatkan kinerja model, mengurangi kompleksitas, serta menghindari *overfitting*.

3.3.2 Algoritma Machine Learning K-Means Clustering

K-Means Clustering adalah algoritma *unsupervised learning* yang digunakan untuk mengelompokkan data ke dalam sejumlah cluster (k) berdasarkan kemiripan karakteristik. Setiap data akan dikelompokkan ke cluster dengan jarak terdekat ke titik pusat *cluster* (*centroid*). Algoritma ini efektif untuk mengidentifikasi pola tersembunyi, segmentasi pasar, atau pengelompokan objek berdasarkan atribut numerik. Dalam penelitian ini, *K-Means* digunakan untuk mengelompokkan entitas seperti penginapan atau pelanggan berdasarkan variabel numerik yang dimiliki. Langkah-langkah yang dilakukan adalah :

1. Menentukan jumlah cluster (k)

Langkah pertama adalah menentukan nilai k , yaitu jumlah kelompok yang ingin dibentuk. Nilai k dapat ditentukan secara manual atau menggunakan metode seperti *Elbow Method* atau *Silhouette Score*.

2. Inisialisasi *centroid* awal

Algoritma akan secara acak memilih k titik awal sebagai *centroid*, yaitu pusat dari masing-masing *cluster*.

3. Menghitung jarak setiap data ke *centroid*

Setiap data akan dihitung jaraknya terhadap seluruh *centroid* menggunakan ukuran seperti *Euclidean Distance*, dan diklasifikasikan ke dalam *cluster* dengan jarak terdekat.

4. Menghitung ulang posisi *centroid*

Setelah semua data dikelompokkan, algoritma menghitung ulang posisi *centroid* dengan mengambil rata-rata dari seluruh titik dalam masing-masing *cluster*.

5. Iterasi hingga konvergen

Langkah 3 dan 4 diulang hingga *centroid* tidak berubah lagi secara signifikan, atau hingga jumlah iterasi maksimum tercapai. Pada tahap ini, *cluster* dianggap stabil.

3.3.3 Algoritma Machine Learning Random Forest Regression

Random Forest Regression adalah salah satu algoritma *supervised learning* berbasis ensemble yang digunakan untuk memprediksi nilai numerik (regresi). Algoritma ini bekerja dengan membangun sejumlah pohon keputusan (*decision trees*) secara acak dan menggabungkan hasil prediksi dari seluruh pohon untuk memperoleh hasil akhir yang lebih akurat dan stabil. Setiap pohon dalam model dilatih pada subset data yang berbeda (menggunakan teknik *bagging*), sehingga meningkatkan kemampuan generalisasi dan mengurangi risiko *overfitting*. Langkah-langkah yang dilakukan adalah:

1. Menentukan variabel target dan fitur input

Langkah awal adalah memisahkan variabel dependen (yang diprediksi) dan independen (fitur yang digunakan sebagai input model).

2. Membagi data menjadi data latih dan data uji

Dataset dibagi menjadi dua bagian, biasanya 70–80% untuk pelatihan dan sisanya untuk pengujian, agar bisa mengevaluasi performa model secara objektif.

3. Membangun banyak pohon keputusan

Algoritma membentuk banyak pohon (biasanya ratusan) secara acak. Setiap pohon dilatih menggunakan subset acak dari data dan fitur.

4. Melakukan prediksi

Setiap pohon memberikan prediksi, dan hasil akhir merupakan rata-rata dari seluruh prediksi pohon (untuk regresi).

5. Evaluasi model

Model dievaluasi menggunakan metrik regresi seperti *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), dan *R-squared* (R^2) untuk menilai ketepatan prediksi.

BAB IV HASIL DAN PEMBAHASAN

4.1 EXPLORATORY DATA ANALYSIS (EDA) DAN DATA-PREPROCESSING

4.1.1 Statistika Deskriptif

Tabel 2. Hasil Statistika Deskriptif

Variabel	Mean	Median	Q1	Q3	Variance	SD	Min	Max
Harga dalam semalam	308565.78	233415.0	153037.5	375644.5	6.22e+10	249411.50	42975.0	1500000
Bintang Penginapan	2.038095	2.0	1.0	3.0	1.39e+00	1.180444	1.0	5.0
Rating	8.243175	8.4	8.0	8.7	6.48e-01	0.805026	4.8	10.0
Jumlah Review	1499.4064	129.0	14.0	1700.0	6.75e+06	2599.5723	1.0	1300.0
Jumlah Fasilitas	25.393651	19.0	7.0	38.5	5.07e+02	22.522825	0.0	115.0

Berdasarkan hasil statistika deskriptif tersebut, dapat terlihat gambaran umum mengenai karakteristik setiap variabel pada dataset tersebut, seperti nilai rata-rata (*mean*), nilai tengah (*median*), kuartil pertama (Q1) dan kuartil ketiga (Q3), variansi, standar deviasi, *range*, jumlah, nilai minimum, serta nilai maksimum.

Rata-rata “Harga dalam semalam” adalah Rp 308.566, dengan median yang lebih rendah (Rp233.415), menunjukkan distribusi harga yang miring ke kanan (*right-skewed*). penginapan umumnya memiliki “*rating*” bintang 2, dengan kisaran 1 hingga 5. “*Rating*” rata-rata penginapan cukup tinggi dan seragam (mean 8.24, SD rendah), sementara “Jumlah *Review*” sangat bervariasi, dari 1 hingga 13.000, yang menunjukkan adanya *outlier*. “Jumlah fasilitas” juga bervariasi besar, dari 0 hingga 115 fasilitas. Secara keseluruhan, banyak variabel menunjukkan distribusi tidak normal dan mengandung nilai ekstrem, yang perlu diperhatikan dalam analisis lanjutan.

4.1.2 Pengecekan dan Penanganan Missing Values

Tabel 3. Hasil Pengecekan Missing Values

Variabel	Jumlah Nilai 0	Persentase Nilai 0 (%)
Jumlah	11	3.492063

Tabel tersebut menunjukkan bahwa dari seluruh data yang dianalisis, terdapat 11 entri pada variabel Jumlah Fasilitas yang memiliki nilai 0, yang dianggap sebagai *missing value*, karena setiap penginapan semestinya memiliki setidaknya satu fasilitas yang disediakan untuk pengunjung. Nilai ini setara dengan 3.49% dari total data.

Keberadaan data kosong seperti ini dapat mengganggu hasil analisis dan menurunkan kualitas model. Oleh karena itu, diputuskan untuk melakukan penanganan dengan cara menghapus (*drop*) baris data yang mengandung nilai 0 pada variabel ini. Langkah ini dianggap tepat mengingat proporsinya yang kecil, sehingga tidak akan memengaruhi representasi data secara keseluruhan, namun tetap menjaga konsistensi dan validitas informasi dalam dataset.

4.1.3 Pengecekan Outlier


Tabel 4. Hasil Pengecekan *Outlier*

Variabel	Jumlah <i>Outlier</i>
Harga dalam semalam	20
Bintang Penginapan	0
<i>Rating</i>	27
Jumlah <i>Review</i>	46
Jumlah Fasilitas	8

Berdasarkan tabel diatas, dapat disimpulkan sebagai berikut:

- Variabel “Harga dalam semalam” memiliki 20 *outlier*, yang mengindikasikan adanya penginapan dengan harga yang jauh di luar rentang umum, baik jauh lebih mahal maupun lebih murah.
- Variabel “Bintang penginapan” tidak memiliki *outlier*, yang berarti nilai pada variabel ini berada dalam kisaran yang wajar dan seragam.
- Variabel “*Rating*” memiliki 27 *outlier*, mengindikasikan adanya penginapan dengan penilaian yang sangat tinggi atau sangat rendah dibandingkan mayoritas lainnya.
- Variabel “Jumlah *Review*” menunjukkan jumlah outlier terbanyak, yaitu 46 *outlier*, menandakan variasi besar dalam banyaknya ulasan yang diterima oleh penginapan-penginapan dalam data.

- Sementara itu, variabel Jumlah Fasilitas memiliki 8 *outlier*, yang berarti terdapat beberapa penginapan dengan jumlah fasilitas yang jauh lebih sedikit atau jauh lebih banyak dibandingkan penginapan lain pada umumnya.



Gambar 2. Boxplot persebaran outlier

Berdasarkan visualisasi *boxplot*, diketahui bahwa variabel Harga dalam semalam memiliki sebaran yang *right-skewed*, dengan mayoritas data berada di bawah 500.000 rupiah. Terlihat pula banyak *outlier* pada nilai harga yang tinggi, bahkan mencapai lebih dari 1 juta rupiah per malam, yang menunjukkan adanya penginapan-penginapan dengan harga jauh di atas rata-rata. Pada variabel Bintang penginapan, data tersebar dari 1 hingga 5 tanpa adanya *outlier*, mengindikasikan bahwa seluruh penginapan berada dalam rentang klasifikasi yang wajar. Sementara itu, pada variabel *Rating*, sebagian besar penginapan memiliki *rating* tinggi antara 8 hingga 9. Namun, terdapat sejumlah *outlier* dengan *rating* rendah, yang mencerminkan adanya penginapan-penginapan dengan penilaian kualitas yang kurang baik. Variabel jumlah *review* menunjukkan persebaran data yang cukup ekstrim, dengan mayoritas penginapan memiliki ulasan di bawah 3.000, tetapi terdapat banyak *outlier* dengan jumlah ulasan yang sangat tinggi hingga lebih dari 10.000, yang menandakan keberadaan penginapan-penginapan populer. Terakhir, pada variabel Jumlah Fasilitas, sebagian besar penginapan memiliki 10 hingga 40 fasilitas, namun terdapat beberapa *outlier* yang memiliki lebih dari 80 fasilitas, bahkan mendekati 100. Hal ini menunjukkan bahwa ada penginapan-penginapan yang menawarkan layanan yang jauh lebih lengkap dibandingkan lainnya.

Outlier dalam penelitian ini tidak dihapus karena dianggap mencerminkan kondisi nyata, seperti penginapan mewah dengan harga tinggi atau fasilitas lengkap. Keberadaan *outlier* memberikan informasi penting yang mencerminkan keberagaman data. Menghapusnya berisiko menghilangkan

insight yang relevan terhadap karakteristik populasi. Oleh karena itu, semua *outlier* tetap dipertahankan dalam proses analisis.

4.1.4 Transformasi Variabel


Pada tahap ini, dilakukan proses transformasi terhadap variabel kategorik menjadi variabel numerik agar dapat digunakan dalam analisis dan pemodelan. Salah satu transformasi yang dilakukan adalah pada variabel nama kota. Variabel ini awalnya berbentuk data kategorik yang merepresentasikan lokasi penginapan berdasarkan nama kota, yang tidak dapat diolah secara langsung oleh algoritma pembelajaran mesin berbasis numerik.

Untuk mengatasi hal tersebut, dilakukan pengubahan variabel nama kota menjadi variabel jarak penginapan ke pusat kota dalam satuan kilometer. Pendekatan ini lebih informatif secara kuantitatif, karena memberikan representasi spasial yang dapat berpengaruh terhadap harga, *rating*, maupun fasilitas penginapan. Dengan kata lain, posisi geografis penginapan diwakili oleh ukuran jarak yang konkret dan dapat dibandingkan antar penginapan. Sehingga data maupun variabel setelah transformasi adalah sebagai berikut.

Tabel 5. Data dan Variabel Setelah Transformasi

No.	Nama Variabel	Non-missing value	Type
1	Nama penginapan	304 non-null	object
2	Jarak dari balai kota	304 non-null	float64
3	Harga dalam semalam	304 non-null	float64
4	Bintang penginapan	304 non-null	int64
5	<i>Rating</i>	304 non-null	float64
6	Jumlah Review	304 non-null	int64
7	Jumlah Fasilitas	304 non-null	int64

4.1.5 Korelasi Antar Variabel



Gambar 3. *Heatmap* Korelasi Variabel Numerik

Berdasarkan hasil visualisasi *heatmap* korelasi antar variabel numerik, diketahui bahwa korelasi paling kuat terjadi antara variabel harga dalam semalam dan bintang penginapan dengan nilai korelasi sebesar 0,54 yang menunjukkan hubungan positif sedang. Artinya, semakin tinggi tingkat bintang penginapan, cenderung semakin mahal harga yang ditawarkan. Selain itu, bintang penginapan juga memiliki korelasi yang cukup tinggi dengan jumlah *review* (0,50) dan jumlah fasilitas (0,50) yang mengindikasikan bahwa penginapan berbintang cenderung memiliki lebih banyak ulasan serta fasilitas yang lebih lengkap. Variabel jumlah fasilitas juga memiliki korelasi sedang dengan jumlah *review* (0,45) dan harga dalam semalam (0,38), yang menunjukkan bahwa penginapan dengan fasilitas lebih banyak cenderung memiliki harga lebih tinggi dan lebih sering di *review*. Di sisi lain, *Rating* menunjukkan korelasi yang sangat lemah dengan seluruh variabel lainnya, dengan nilai korelasi tertinggi hanya sebesar 0,28 dengan bintang penginapan. Hal ini menandakan bahwa penilaian atau *rating* penginapan tidak terlalu bergantung pada harga, jumlah fasilitas, maupun jumlah ulasan yang dimiliki.

4.2 HASIL ANALISIS

4.2.1 *K-Means Clustering*

Pada analisis ini, kami menggunakan algoritma *K-Means* untuk melakukan analisis *clustering* untuk mengelompokkan data berdasarkan kemiripannya antar *feature* satu sama lain seperti Bintang penginapan, *Rating*, Jumlah *Review*, Jumlah Fasilitas dan Jarak dari balai kota. Karena analisis *clustering* merupakan metode *unsupervised learning*, langkah pertama yang kami lakukan adalah menghapus variabel 'Harga dalam semalam'. Hal ini

dilakukan untuk mencegah variabel tersebut memberikan pengaruh yang tidak diinginkan dalam proses *clustering*, sehingga *cluster* yang terbentuk dapat mencerminkan pola yang lebih natural dan objektif tanpa terdistorsi oleh faktor harga.

```
data_cluster = data.copy()

var = ['Jarak dari balai kota', 'Bintang Hotel', 'Rating',
      'Jumlah Review', 'Jumlah Fasilitas']
x = data_cluster[var]
```

✓ 0.0s

Gambar 4. Kode untuk memisahkan variabel ‘Harga dalam semalam’

Langkah selanjutnya yang akan dilakukan adalah melakukan standarisasi terhadap data, mengingat adanya *outlier* yang teridentifikasi dengan nilai yang sangat ekstrim pada data yang kami kumpulkan. Keputusan untuk tidak menghapus *outlier* tersebut didasarkan pada keterbatasan jumlah data yang tersedia. Selain itu, penting untuk dicatat bahwa algoritma *K-means* yang digunakan dalam analisis ini memiliki sensitivitas yang tinggi terhadap keberadaan *outlier*. Oleh karena itu, standarisasi menjadi langkah yang diperlukan untuk mengurangi pengaruh outlier terhadap hasil *clustering* yang lebih representatif dan akurat.

```
scaler = StandardScaler()
x_scaled = scaler.fit_transform(x)
```


✓ 0.0s

Gambar 5. Kode untuk Standarisasi

Selanjutnya, langkah berikutnya adalah melakukan clustering menggunakan algoritma *K-means* dengan jumlah *cluster* sebanyak 3. Tujuan dari *clustering* ini adalah untuk mengelompokkan penginapan berdasarkan kategori harga, yaitu rendah, menengah, dan mahal, dengan mempertimbangkan variabel-variabel selain harga. Dengan cara ini, kami berharap *cluster* yang terbentuk dapat mencerminkan karakteristik penginapan secara lebih natural tanpa dipengaruhi oleh variabel harga, sehingga pengelompokan lebih akurat dan representatif terhadap faktor-faktor lain yang mempengaruhi kategori harga tersebut.

Setelah terbentuk tiga *cluster* sesuai yang kami inginkan, dengan rincian *cluster* 0 sebanyak 75 data, *cluster* 1 sebanyak 137 data, dan *cluster* 2 sebanyak 92 data, langkah selanjutnya adalah menggabungkan data yang telah dikelompokkan tersebut dengan variabel harga yang sebelumnya telah dipisahkan. Tujuan dari penggabungan ini adalah untuk menganalisis distribusi harga pada setiap *cluster* dan sekaligus menentukan *cluster* mana

yang paling mewakili kelas harga yang telah kami tentukan, yaitu rendah, menengah, dan mahal. Dengan cara ini, kami dapat memverifikasi apakah *clustering* yang dilakukan berhasil mengelompokkan penginapan sesuai dengan kategori harga yang diinginkan.



Gambar 6. Distribusi harga untuk setiap *cluster*

Berdasarkan distribusi harga setiap *cluster* tersebut, dapat disimpulkan bahwa *cluster* 0 mewakili penginapan dengan harga murah, *cluster* 1 mewakili penginapan dengan harga menengah dan *cluster* 2 mewakili penginapan dengan harga mahal. Dari informasi tersebut kita bisa menentukan *range* harga untuk setiap kelas tersebut dengan mengambil rata-rata dari kuartil 3 *cluster* sebelum dan kuartil 1 *cluster* sesudahnya. Berikut adalah Q1, Q2 (median) dan Q3 dari setiap *cluster* :

Tabel 6. Kuartil Tiap *Cluster*

<i>Cluster</i>	Q1	Q2 (Median)	Q3
0	119973.0	152838.0	214162.5
1	151824.0	194242.0	309917.0
2	262080.0	332802.0	515082.25

Dari informasi tersebut, kita bisa membentuk *range* harga dari setiap kelas berdasarkan Q1 dan Q3 dari setiap *cluster* melalui rata-rata dari kuartil 3 *cluster* sebelum dan kuartil 1 *cluster* sesudahnya. Untuk alasan menggunakan Q1 dan Q3 sebagai penentu *range* harga adalah karena kuartil merupakan ukuran posisi dalam distribusi data yang tidak terpengaruh terhadap *outlier*. Sehingga dari Q1 dan Q3 dari setiap *cluster* tersebut, didapatkan *range* harga dari setiap kelas berdasarkan data yang kami dapatkan sebagai berikut :

- Harga penginapan yang termasuk dalam golongan murah : Rp.182993.25 kebawah
- Harga penginapan yang termasuk dalam golongan menengah : Rp.182993.25 - Rp.285998.5
- Harga penginapan yang termasuk dalam golongan mahal : Rp.285998.5 keatas

4.2.2 *Random Forest Regression*

Pada metode analisis prediktif ini kami menggunakan model *Random Forest Regression* sebagai model kita untuk melakukan prediksi terhadap variabel harga. untuk alasan kami menggunakan *Random Forest Regression* sendiri karena *Random Forest Regression* adalah salah satu model yang agak tahan terhadap *outlier* dan itu sangat cocok dengan data kita yang memiliki *outlier* dalam datanya sehingga kita tidak perlu untuk membuang data *outlier* dikarenakan keterbatasan data yang kita miliki.

Langkah pertama yang kami lakukan yaitu memisahkan variabel y dengan variabel x yang akan digunakan untuk memprediksi. Setelah itu data dibagi menjadi *data test* sebanyak 20% dan *data train* sebanyak 80% sehingga nantinya model yang dihasilkan dapat dievaluasi menggunakan data yang belum dimasukkan dalam model.

```
var = ['Jarak dari balai kota', 'Bintang Hotel', 'Rating', 'Jumlah Review', 'Jumlah Fasilitas']

x = data_regresi[var]
y = data_regresi['Harga dalam semalam']

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)
```

Gambar 7. Kode untuk membagi data menjadi data X dan Y serta membagi data menjadi *data train* dan *data test*.

Langkah selanjutnya adalah melakukan *train* pada *data train* sekaligus melakukan evaluasi terhadap modelnya menggunakan *data test* yang sudah dipisahkan sebelumnya. Evaluasi dilakukan dengan menggunakan metrik RMSE (*Root Mean Square Error*) untuk mengukur seberapa besar galat prediksi yang dihasilkan model, serta R-squared (R^2) untuk menilai seberapa baik model dalam menjelaskan variasi data target. Setelah dilakukan pelatihan model untuk pertama kalinya, model kami mendapatkan RMSE sebesar 151078.44 dan R^2 sebesar 0.5524. karena dirasa belum puas dengan hasil yang diperoleh, maka kami melakukan penambahan fitur dengan mengkombinasikan beberapa variabel menjadi variabel yang baru.

Langkah pertama yang kami lakukan adalah menganalisis korelasi antar variabel untuk menentukan variabel-variabel yang dapat dikombinasikan menjadi variabel baru. Proses ini dilakukan dengan memanfaatkan *heatmap* yang telah kami peroleh sebelumnya. Berdasarkan hasil analisis korelasi, kami menemukan korelasi tertinggi antara variabel harga dan bintang penginapan, variabel fasilitas dan bintang penginapan, serta variabel fasilitas dan harga.

Meskipun terdapat beberapa korelasi tinggi lainnya, seperti antara jumlah *review* dan jumlah bintang, namun secara logika korelasi tersebut tidak relevan, sehingga kami memutuskan untuk hanya mempertimbangkan korelasi yang tinggi dan masuk akal secara logis. Selain itu, kami juga menemukan bahwa data *rating* yang kami peroleh cenderung tinggi, namun jumlah *review*nya sangat sedikit, yang berpotensi menimbulkan bias dalam pembuatan model. Oleh karena itu, kami menciptakan variabel baru dengan mengalikan variabel *rating* dengan jumlah *review*. Hal ini bertujuan untuk membedakan antara penginapan dengan *rating* tinggi yang disebabkan oleh jumlah *review* yang banyak dan penginapan dengan *rating* tinggi yang hanya berasal dari sedikit *review*.

```
data_regresi = data.copy()

data_regresi['harga_per_bintang'] = data_regresi['Harga dalam semalam'] / data_regresi['Bintang Hotel']
data_regresi['harga_per_fasilitas'] = data_regresi['Harga dalam semalam'] / data_regresi['Jumlah Fasilitas']
data_regresi['fasilitas_per_bintang'] = data_regresi['Jumlah Fasilitas'] / data_regresi['Bintang Hotel']
data_regresi['rating_x_review'] = data_regresi['Rating'] * data_regresi['Jumlah Review']

var = ['Jarak dari balai kota', 'Bintang Hotel', 'Rating', 'Jumlah Review', 'Jumlah Fasilitas',
      'harga_per_bintang', 'harga_per_fasilitas', 'rating_x_review', 'fasilitas_per_bintang']

x = data_regresi[var]
y = data_regresi['Harga dalam semalam']

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.2, random_state=42)
✓ 0.0s
```

Gambar 8. Kode untuk menambahkan *feature* baru

Dengan melakukan *training* ulang pada data yang sudah kami lakukan penambahan *feature* dengan menggunakan model dan pengaturan yang sama dengan yang sebelumnya, kami berhasil mendapatkan RMSE sebesar 72.412,61 dan R^2 sebesar 0,8972. Penambahan *feature* tersebut memberikan dampak signifikan terhadap performa model, jika dibandingkan dengan hasil sebelumnya yang memiliki RMSE sebesar 151.078,44 dan R^2 sebesar 0,5524.

BAB V

KESIMPULAN DAN SARAN

5.1 KESIMPULAN

Penelitian ini bertujuan untuk menganalisis dan memprediksi harga penginapan di Surabaya yang tersedia pada aplikasi Traveloka dengan menggunakan metode *K-Means Clustering* untuk segmentasi dan *Random Forest Regression* untuk prediksi harga. Dari total 315 data penginapan yang dikumpulkan melalui web scraping, dilakukan serangkaian proses *preprocessing* termasuk penanganan *missing values*, deteksi *outlier*, transformasi variabel, dan analisis korelasi antar fitur. Hasil segmentasi menggunakan *K-Means* berhasil mengelompokkan penginapan ke dalam tiga kelas harga, yaitu kategori murah ($\leq$ Rp182.993,25), menengah (Rp182.993,25 – Rp285.998,5), dan mahal ($>$ Rp285.998,5). Segmentasi dilakukan tanpa memasukkan variabel harga dalam proses pembentukan *cluster*, sehingga hasil yang diperoleh lebih alami dan menggambarkan kecenderungan nyata dari atribut-atribut lain seperti bintang penginapan, jumlah fasilitas, ulasan pengguna, dan jarak ke pusat kota.

Dalam hal prediksi harga, penggunaan algoritma *Random Forest* terbukti efektif, terlebih setelah dilakukan penambahan fitur hasil kombinasi antar variabel yang memiliki korelasi kuat dan relevan secara logika, seperti produk antara *rating* dan jumlah ulasan. Model awal memiliki performa dengan R^2 sebesar 0,5524 dan RMSE sebesar Rp151.078,44. Namun setelah penambahan fitur, performa meningkat signifikan dengan R^2 sebesar 0,8972 dan RMSE menurun drastis menjadi Rp72.412,61. Ini menunjukkan bahwa pemilihan fitur dan pengayaan variabel sangat berperan dalam meningkatkan akurasi prediktif model. Faktor-faktor yang paling berpengaruh terhadap harga penginapan berdasarkan model adalah jumlah bintang, jumlah fasilitas, dan jumlah ulasan pengguna, yang secara langsung mencerminkan kualitas dan popularitas penginapan.

Hasil penelitian ini memberikan kontribusi praktis dan teoritis. Secara praktis, konsumen dapat memanfaatkan informasi segmentasi dan prediksi harga untuk menentukan pilihan penginapan yang sesuai kebutuhan dan anggaran. Sementara itu, bagi pelaku industri penginapan, temuan ini dapat menjadi dasar dalam strategi penentuan harga dan peningkatan layanan. Secara teoritis, kombinasi metode clustering dan regresi dalam konteks data akomodasi memberikan pendekatan baru dalam eksplorasi pasar berbasis data.

5.2 SARAN

Untuk pengembangan penelitian selanjutnya, disarankan agar data yang digunakan diperluas baik dari segi jumlah maupun cakupan wilayah, misalnya mencakup kota-kota lain selain Surabaya agar model prediksi dapat lebih general dan tidak bias terhadap karakteristik lokal tertentu. Selain itu, faktor yang perlu diperhatikan yaitu faktor temporal seperti musim liburan, akhir pekan, atau hari besar nasional, karena hal ini mempengaruhi fluktuasi harga penginapan secara signifikan. Penggunaan algoritma lain seperti XGBoost atau LightGBM juga patut

dipertimbangkan untuk dibandingkan performanya dengan *Random Forest*, khususnya dalam menangani data yang lebih besar dan kompleks.

Bagi platform Traveloka, disarankan untuk mengintegrasikan fitur segmentasi harga otomatis dan sistem rekomendasi berbasis preferensi pengguna, yang tidak hanya mempertimbangkan harga, tetapi juga kualitas layanan berdasarkan *rating* dan ulasan pengguna. Fitur seperti ini akan sangat membantu pengguna dalam mengambil keputusan yang lebih efisien. Sementara itu, bagi pelaku industri penginapan, hasil penelitian ini dapat menjadi masukan penting untuk strategi pemasaran, pengelolaan layanan, serta penentuan harga yang lebih kompetitif dan berbasis data. Upaya meningkatkan fasilitas dan kualitas layanan terbukti memiliki korelasi kuat terhadap harga dan persepsi pelanggan, sehingga perlu menjadi perhatian utama dalam pengembangan bisnis jangka panjang.

DAFTAR PUSTAKA

- Handoko, K. (2016). Penerapan Data Mining dalam Meningkatkan Mutu Pembelajaran Menggunakan Metode K-MEANS Clustering. *Jurnal Nasional Teknologi Dan Sistem Informasi*, 2(3), 31–40. <https://doi.org/10.25077/TEKNOSI.v2i3.2016.31-40>
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and. Techniques*, Waltham: Morgan Kaufmann Publishers.
- Hastie, T. (2009). *The elements of statistical learning: data mining, inference, and prediction*.
- Mohr, Donna L., Wilson, William J., Freund, Rudolf J.. 2022. “Statistical Methods (Fourth Edition)”.
- Pramoedyo, H. (2022). Komparasi akurasi metode Random Forest dan Deep Learning pada klasifikasi data. *Jurnal Informatika*, 9(2), 45–55. <https://doi.org/10.5220/0012464600003636>
- Ross, Sheldon M.. 2017. “Introductory Statistic”.
- Tan, P.-N., Steinbach, M., & Kumar, V. (2019). *Introduction to Data Mining* (2nd ed.). Pearson.

LAMPIRAN

Kode Scrapping : [playwright_datmin.py](#)

Data Mentah : [data datmin mentah.csv](#)

Kode Preprocessing : [Kode Preprocessing.ipynb](#)

Data setelah Preprocessing : [data_final_datmin.csv](#)

Kode Analisis : [Kode_cluster_dan_regresi.ipynb](#)